

Explicación Teórica: t-SNE y K-Means-Datos de Revistas

Nicolás Chasin Pincay

2025-01-13

Introducción

Este documento describe la teoría detrás del análisis realizado en el código proporcionado. Se explican conceptos fundamentales como la reducción de dimensionalidad con **t-SNE**, el agrupamiento mediante **K-Means**, y los pasos asociados al preprocesamiento y visualización de datos.

Preparación de Datos

Datos Multivariantes

Los datos multivariantes son observaciones con múltiples variables, comunes en áreas como economía, biología y ciencias sociales. Para trabajar con este tipo de datos:

1. **Consistencia:** Asegúrate de que todas las tablas tengan dimensiones similares.
2. **Estructuración:** Combina las tablas en una sola matriz para un análisis conjunto.

En este caso, se trabajan tres tablas:

- **Años:** Información por año.
- **Revistas:** Datos relacionados con revistas científicas.
- **Países:** Información categórica y numérica por país.

El objetivo de este paso es crear una matriz numérica combinada para aplicar las técnicas posteriores.

Transformación CLR (Centered Log-Ratio)

Teoría

Los datos composicionales representan proporciones (por ejemplo, porcentajes). Debido a su naturaleza (la suma constante de los componentes), no pueden analizarse directamente con técnicas tradicionales. La **transformación CLR** los convierte en un espacio euclidiano.

Sea un vector composicional $x = [x_1, x_2, \dots, x_D]$, la transformación CLR se define como:

$$\text{clr}(x) = \left[\ln \left(\frac{x_1}{g(x)} \right), \ln \left(\frac{x_2}{g(x)} \right), \dots, \ln \left(\frac{x_D}{g(x)} \right) \right]$$

donde $g(x)$ es la media geométrica de x :

$$g(x) = \sqrt[p]{x_1 \cdot x_2 \cdot \dots \cdot x_D}$$

Aplicación

1. Se aplica CLR a los datos combinados para eliminar las restricciones de suma constante.
2. Esto facilita el uso de técnicas como t-SNE y K-Means.

Reducción de Dimensionalidad: t-SNE

Teoría

t-SNE proyecta datos de alta dimensionalidad a un espacio reducido, preservando relaciones locales entre puntos.

Sea f la transformación:

$$f : \mathbb{R}^D \rightarrow \mathbb{R}^d \quad \text{donde } d < D$$

El objetivo es que las similitudes entre puntos en el espacio reducido sean consistentes con las del espacio original.

Similitud y Probabilidades

En el espacio de alta dimensionalidad

La similitud entre puntos i y j se mide mediante una distribución gaussiana:

$$P_{j|i} = \frac{\exp(-\|x_i - x_j\|^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|x_i - x_k\|^2 / 2\sigma_i^2)}$$

donde: - x_i y x_j son puntos en el espacio original. - σ_i controla la escala local.

Para simetrizar, se define:

$$P_{ij} = \frac{P_{j|i} + P_{i|j}}{2n}$$

En el espacio reducido

En el espacio reducido, las similitudes se modelan con una distribución t de Student:

$$Q_{ij} = \frac{(1 + \|y_i - y_j\|^2)^{-1}}{\sum_{k \neq l} (1 + \|y_k - y_l\|^2)^{-1}}$$

donde y_i y y_j son puntos en el espacio reducido.

Minimización de Divergencia KL

t-SNE minimiza la divergencia de Kullback-Leibler (KL) entre P_{ij} y Q_{ij} :

$$C = \sum_{i \neq j} P_{ij} \log \frac{P_{ij}}{Q_{ij}}$$

Esta minimización se realiza iterativamente.

Clustering con K-Means

Teoría

K-Means agrupa datos en k clusters, donde los puntos de un cluster son similares y distintos de otros clusters.

Funcionamiento

1. **Inicialización:** Se seleccionan k centroides iniciales.
2. **Asignación:** Cada punto se asigna al cluster más cercano:

$$\text{Cluster}(i) = \arg \min_j \|x_i - \mu_j\|$$

donde x_i es un punto y μ_j el centroide.

3. **Actualización de centroides:** Los centroides se recalculan:

$$\mu_j = \frac{1}{|C_j|} \sum_{x_i \in C_j} x_i$$

4. **Iteración:** Se repiten los pasos 2 y 3 hasta convergencia.

Criterio de Evaluación

K-Means minimiza la suma de distancias cuadradas dentro de los clusters:

$$WSS = \sum_{j=1}^k \sum_{x_i \in C_j} \|x_i - \mu_j\|^2$$

Visualización y Resultados

1. **Coordenadas t-SNE:** Permiten visualizar la distribución de datos en 2D.
2. **Clusters:** Ayudan a identificar agrupaciones naturales.
3. **Etiquetas descriptivas:** Facilitan la interpretación de los resultados.

Interpretación de la Gráfica

La gráfica generada muestra la proyección de las observaciones en un espacio de dos dimensiones, obtenida mediante t-SNE, junto con los clusters asignados por K-Means. Cada punto está etiquetado con información descriptiva (Año:Revista:País) para facilitar su interpretación.

Identificación de Clusters

- Los puntos están agrupados en **cuatro clusters**, identificados por colores:
 - **Rojo:** Cluster 1
 - **Azul:** Cluster 2
 - **Verde:** Cluster 3
 - **Naranja:** Cluster 4

Cada cluster representa un grupo de observaciones con características similares en el espacio reducido.

Relaciones Locales y Globales

Relaciones Locales

t-SNE garantiza que las relaciones locales entre puntos se preserven en el espacio reducido. Es decir: - Los puntos cercanos en la gráfica eran también cercanos en el espacio original de alta dimensionalidad. - Dentro de cada cluster, las observaciones tienen características comunes.

Diferencias Globales

Los clusters están separados en la gráfica, indicando diferencias significativas entre los grupos. Esto sugiere que las observaciones en diferentes clusters tienen patrones o características distintivas en los datos originales.

Análisis de Clusters

Distribución de los Clusters

Cluster 1 (Rojo)

- Este cluster contiene puntos dispersos, pero con concentraciones en el cuadrante derecho superior e inferior derecho.
- Ejemplo de observaciones:
 - **2024:Sustainability:USA**, que podría estar relacionado con enfoques ambientales y sostenibles.
- Este cluster podría representar investigaciones enfocadas en sostenibilidad o países con características específicas.

Cluster 2 (Azul)

- Observaciones más concentradas en la parte inferior de la gráfica.
- Ejemplo:
 - **1996:Animals:Australia**.
- Este cluster parece agrupar observaciones de revistas y países con características homogéneas.

Cluster 3 (Verde)

- Las observaciones están distribuidas principalmente en el centro de la gráfica.
- Ejemplo:
 - **1997:Appl. Sci. Basel:Bangladesh.**
- Podría reflejar un grupo de datos más equilibrado o intermedio en términos de similitudes.

Cluster 4 (Naranja)

- Este cluster tiene puntos más dispersos en la parte superior de la gráfica.
- Ejemplo:
 - **2017:Nongye Gongcheng Xuebao:Portugal.**
- Representa un grupo con menor similitud interna o características más diversas.

Uso de Etiquetas

Cada punto está etiquetado con el formato **Año:Revista:País**. Esto permite identificar:

1. **Año:** Posibles tendencias temporales en la investigación.
2. **Revista:** Enfoque o tema de publicación.
3. **País:** Contexto geográfico de la investigación.

Por ejemplo: - **2018:PLOS ONE:South Korea** está en el Cluster 1 (Rojo), lo que sugiere que comparte características con otros puntos de este cluster.

Relaciones entre Clusters

Las distancias entre clusters en la gráfica sugieren:

1. **Cluster 3 (Verde) y Cluster 2 (Azul):**
 - Estos clusters parecen estar más cercanos, indicando posibles similitudes entre sus observaciones.
2. **Cluster 4 (Naranja):**
 - Es más disperso y distante, lo que podría reflejar observaciones con características únicas o fuera de lo común.

Insights Derivados

Homogeneidad dentro de los Clusters

Las observaciones dentro de cada cluster comparten características similares. Esto puede reflejar:

- Enfoques comunes en las revistas.
- Patrones geográficos específicos.
- Relación temporal en los años analizados.

Tendencias Temporales

Analizar la distribución de los años entre los clusters puede revelar patrones a lo largo del tiempo:

- Por ejemplo, investigaciones más recientes como **2024:Sustainability:USA** podrían estar más enfocadas en temas sostenibles, mientras que publicaciones más antiguas se agrupan en otros clusters.

Representación Geográfica

La presencia de países en cada cluster puede reflejar diferencias geográficas en los temas de investigación.

Conclusión

El análisis de los resultados mediante **t-SNE** y **K-Means** permite identificar:

1. **Clusters naturales:** Agrupaciones de observaciones con características similares.
2. **Relaciones complejas:** Patrón global de similitudes y diferencias entre grupos.
3. **Información contextual:** Etiquetas descriptivas facilitan la interpretación y relacionan los puntos con su origen (año, revista, país).

Este enfoque proporciona una poderosa herramienta para explorar datos multivariantes y descubrir patrones ocultos que serían difíciles de detectar en espacios de alta dimensionalidad.